Anexo — utilização de IAG

HikeFlora · Inteligência Computacional · Meta I · 2026/27

Este anexo resume os pedidos usados na preparação do trabalho. Os campos «Minha análise» são propostas de redação para o grupo rever e assumir apenas se corresponderem ao seu processo. Os resultados citados foram conferidos com os ficheiros do projeto.

Tarefa 1 · definição do dataset

Prompt (excerto/síntese): Escolher 10–12 mil imagens para cinco espécies e explicar a seleção.

Resposta IAG (síntese): Foi proposto um subconjunto equilibrado do Pl@ntNet-300K-v2, com partições separadas e seleção reproduzível a partir dos metadados.

Minha análise (rascunho): Proposta para rever: verifiquei se as classes e os órgãos escolhidos eram adequados ao objetivo da aplicação e mantive o teste independente.

Resultado: selecao_imagens.csv; cinco classes; 11 000 imagens.

Tarefa 1 · alteração de espécie

Prompt (excerto/síntese): Pode mudar para o 237. Depois diga exatamente o que fazer.

Resposta IAG (síntese): O morangueiro cultivado ID 641 foi substituído pelo morangueiro silvestre ID 237, com imagens suficientes para 2 200 exemplos equilibrados.

Minha análise (rascunho): Proposta para rever: aceitei a substituição por melhor cobertura de imagens e adequação ao contexto das caminhadas.

Resultado: ID 237 = Fragaria vesca; 1 760/220/220 imagens.

Tarefa 1 · obtenção das imagens

Prompt (excerto/síntese): Devo baixar os 40 GB? Onde abrir o terminal e que comando executar?

Resposta IAG (síntese): Foi explicado que o arquivo oficial images.zip é necessário uma vez e que o script extrai apenas os caminhos do manifesto, na pasta do projeto.

Minha análise (rascunho): Proposta para rever: segui os comandos localmente e mantive o arquivo completo fora do Git.

Resultado: extrair_imagens.py; dataset/ em treino, validação e teste.

Tarefa 1 · verificação

Prompt (excerto/síntese): Envio o resultado do PowerShell. Concluímos a meta 1?

Resposta IAG (síntese): A saída mostrava 11 000 imagens, 1 760/220/220 por espécie e zero ficheiros em falta ou ilegíveis.

Minha análise (rascunho): Proposta para rever: confirmei que os caminhos e a leitura das imagens estavam corretos antes do treino.

Resultado: verificar_dataset.py; verificação técnica concluída.

Tarefa 1 · Git

Prompt (excerto/síntese): Criar gitignore para a pasta do trabalho e manter fora do Git os ficheiros desnecessários.

Resposta IAG (síntese): Foi preparado um .gitignore para o dataset extraído, o arquivo images.zip, modelos gerados e ficheiros temporários.

Minha análise (rascunho): Proposta para rever: as imagens e os pesos permanecem locais; o código e o manifesto ficam versionados.

Resultado: .gitignore; repositório com código e metadados.

Tarefa 2 · modelos iniciais

Prompt (excerto/síntese): Implementar soluções MLP ou CNN em Python simples, com comentários e parâmetros documentados.

Resposta IAG (síntese): Foram criados modelos MLP e CNN de 128×128 RGB, com Adam 0,001, batch 32 e dez épocas; os históricos e modelos são guardados separadamente.

Minha análise (rascunho): Proposta para rever: mantive arquiteturas pequenas e legíveis para explicar cada camada na defesa.

Resultado: treinar.py; arquiteturas.md; modelos e CSV locais.

Tarefa 2 · ambiente Windows

Prompt (excerto/síntese): O TensorFlow falhou com caminho longo e depois mostrou mensagens oneDNN.

Resposta IAG (síntese): Foi sugerido um ambiente virtual num caminho curto. As mensagens oneDNN foram identificadas como informativas, após a importação funcionar.

Minha análise (rascunho): Proposta para rever: confirmei a versão do TensorFlow antes de voltar a treinar.

Resultado: Ambiente hfvenv; treino executado em Windows.

Tarefa 2 · leitura dos históricos

Prompt (excerto/síntese): Os históricos MLP e CNN já cumprem arquitetura, treino e teste?

Resposta IAG (síntese): A IAG distinguiu validação de teste independente: a CNN original mostrou 99,62% no treino e 70,55% na validação na época 10, sugerindo sobreajuste.

Minha análise (rascunho): Proposta para rever: não usei a validação como métrica final e reservei o teste para a avaliação posterior.

Resultado: mlp_historico.csv e cnn_historico.csv; teste ainda por fazer nesse ponto.

Tarefa 3 · novas configurações

Prompt (excerto/síntese): Sugerir pelo menos três configurações para reduzir o sobreajuste e indicar como testar.

Resposta IAG (síntese): Foram propostas paragem antecipada, dropout 0,5 e aumento de dados com inversão horizontal e rotação pequena, mantendo os restantes parâmetros iguais.

Minha análise (rascunho): Proposta para rever: comparei as variantes pela menor perda de validação, sem consultar o teste.

Resultado: treinar_variacoes.py; tres históricos distintos.

Tarefa 3 · aviso JPEG

Prompt (excerto/síntese): O que significa «Corrupt JPEG data: extraneous bytes» durante o treino?

Resposta IAG (síntese): Foi explicado que o leitor encontrou bytes adicionais num JPEG, mas conseguiu continuar o treino; o mesmo aviso reaparece quando a imagem é lida noutra época.

Minha análise (rascunho): Proposta para rever: mantive o dataset igual nas experiências para permitir comparação.

Resultado: Treinos concluídos; aviso não interrompeu a execução.

Tarefa 3 · escolha por validação

Prompt (excerto/síntese): Envio os resultados das três variações.

Resposta IAG (síntese): A CNN com dropout teve a menor val_loss (0,7386) na época 6, com val_accuracy de 72,18%; foi escolhida antes de usar o teste.

Minha análise (rascunho): Proposta para rever: distingui a melhor accuracy da época 5 (72,64%) dos pesos realmente guardados na época 6.

Resultado: cnn_dropout.keras selecionado; comparacao_validacao.md.

Tarefa 3 · avaliação e bloqueio

Prompt (excerto/síntese): O script de avaliação falhou porque a política do Windows bloqueou scikit-learn.

Resposta IAG (síntese): O cálculo de accuracy, recall, especificidade, F1, AUC e matriz de confusão foi refeito com NumPy e verificado por comparação com valores de referência.

Minha análise (rascunho): Proposta para rever: voltei a executar o teste somente após corrigir o programa, sem ajustar os modelos com os seus resultados.

Resultado: avaliar_teste.py sem scikit-learn; avaliacao_teste.txt.

Tarefa 3 · interpretação do teste

Prompt (excerto/síntese): Envio o ficheiro com a avaliação no teste independente.

Resposta IAG (síntese): A CNN com dropout alcançou accuracy 74,00%, F1 macro 74,25% e AUC macro 93,49%, acima da MLP (47,55%, 45,28% e 81,89%). Foram identificadas confusões entre trevo-branco e morangueiro.

Minha análise (rascunho): Proposta para rever: confirmei que cada classe tinha 220 imagens e que os acertos nas matrizes coincidiam com a accuracy.

Resultado: 814 acertos da CNN e 523 da MLP em 1 100 imagens.

Tarefa 4 · preparação da entrega

Prompt (excerto/síntese): Preparar toda a meta 4, publicar no GitHub e deixar relatório e apresentação editáveis.

Resposta IAG (síntese): Foram organizados o relatório até 10 páginas, os slides, o anexo de IAG, os resultados e o código para revisão final do grupo.

Minha análise (rascunho): Proposta para rever: devo conferir nomes, referências, discussão e ficheiros antes da submissão definitiva.

Resultado: relatorio_meta1.pdf/docx; apresentacao_meta1.pptx/pdf; anexo_prompts_ia.pdf/docx; ZIP inicial.