HikeFlora

Classificação de cinco espécies de plantas em fotografias

Relatório técnico — Meta I · Inteligência Computacional · 2026/27

Rodrigo Cerdeira · 2023141202

Giancarlo Peixoto · 2021135803

Licenciatura em Engenharia Informática · Professor Carlos Pereira

10 de outubro de 2026

Resumo

O HikeFlora estuda a identificação visual de cinco espécies de plantas relevantes para caminhadas. Foram selecionadas 11 000 fotografias do Pl@ntNet-300K-v2, com classes equilibradas e partições independentes de treino, validação e teste. Compararam-se uma MLP e várias CNN simples. A CNN com dropout foi escolhida pela menor perda de validação e alcançou 74,00% de accuracy e 74,25% de F1 macro em 1 100 imagens de teste. A classificação visual não determina se uma planta é segura para ingestão ou contacto.

Palavras-chave: classificação de imagens; plantas; MLP; CNN; validação; matriz de confusão.

1. Caso de estudo e objetivos

1.1 Problema e âmbito

Durante uma caminhada, uma pessoa pode ter dificuldade em reconhecer uma planta. O objetivo desta Meta I é prever, a partir de uma fotografia, qual das cinco espécies abrangidas é a mais provável: gerânio (Pelargonium zonale), alfazema (Lavandula angustifolia), papoila (Papaver rhoeas), trevo-branco (Trifolium repens) ou morangueiro silvestre (Fragaria vesca). A apresentação inicial do HikeFlora prevê, para fases posteriores, fichas documentadas sobre ingestão e contacto, alternativas e um resultado inconclusivo. Essas funcionalidades não foram implementadas nesta Meta I. Uma previsão não é uma recomendação de consumo [1, 2].

1.2 Origem e caracterização dos dados

A fonte é o Pl@ntNet-300K-v2, com 306 087 imagens de 1 000 espécies [3]. Este trabalho usa um subconjunto próprio de 11 000 fotografias. Foi mantida a separação original em treino, validação e teste. De cada classe foram escolhidas 2 200 imagens com semente 42: 1 760 para treino, 220 para validação e 220 para teste. Assim, cada classe representa 20% de cada partição.

ID	Espécie	Treino	Validação	Teste	Total
8	Gerânio	1 760	220	220	2 200
172	Alfazema	1 760	220	220	2 200
200	Papoila	1 760	220	220	2 200
225	Trevo-branco	1 760	220	220	2 200
237	Morangueiro silvestre	1 760	220	220	2 200
—	Total	8 800	1 100	1 100	11 000

A seleção incluiu as etiquetas de órgão flower, leaf, fruit e habit: 6 974 flores, 3 416 folhas, 505 frutos e 105 plantas inteiras. Excluíram-se bark, branch e other. O manifesto selecao_imagens.csv regista os caminhos, a classe, a partição, o órgão, o autor e a licença de cada fotografia. Os 11 000 identificadores de imagem são únicos e não há identificadores de observação repetidos entre partições. A verificação local confirmou os 11 000 ficheiros, sem ausências ou ficheiros ilegíveis. A leitura técnica não garante que todos os rótulos estejam corretos.

As imagens originais têm dimensões variáveis. No carregamento, são redimensionadas para 128 × 128 píxeis RGB: 49 152 valores por imagem, divididos por 255 no modelo. Não houve uma etapa separada de extração manual de características. O subconjunto de cinco classes não é um benchmark publicado; resultados de sistemas treinados nas 1 000 classes de origem não são diretamente comparáveis. O estado de referência específico deste subconjunto é a comparação interna entre MLP e CNN aqui apresentada.

2. Modelo e algoritmos

2.1 Implementação e arquiteturas

A implementação usa Python 3.12 e TensorFlow/Keras. As pastas dataset/train, dataset/val e dataset/test são lidas pela ordem fixa dos IDs 0008, 0172, 0200, 0225 e 0237. Apenas treino e validação entram na escolha da arquitetura. O teste de 1 100 imagens é usado depois dessa decisão. Os dois modelos iniciais usam batch de 32, 10 épocas, Adam com taxa de aprendizagem 0,001, perda sparse categorical crossentropy e semente 42.

Solução	Camadas após entrada RGB 128×128	Parâmetros
MLP	Rescaling; Flatten; Dense 64 (ReLU); Dense 5 (softmax)	3 146 117
CNN	Rescaling; Conv 16 (3×3, ReLU); MaxPool 2×2; Conv 32 (3×3, ReLU); MaxPool 2×2; Flatten; Dense 64 (ReLU); Dense 5 (softmax)	1 848 677

A MLP recebe todos os píxeis como um vetor. A CNN aprende padrões locais por convoluções e reduz as dimensões espaciais por pooling. A versão com dropout mantém a arquitetura da CNN e desativa aleatoriamente 50% das saídas da camada Dense 64 durante o treino; no teste, o dropout não altera as previsões. O número de parâmetros treináveis mantém-se em 1 848 677.

2.2 Comparação controlada

A CNN original apresentou aumento da perda de validação depois das primeiras épocas. Foram comparadas três variações com o mesmo conjunto de dados, batch, taxa de aprendizagem e semente. Todas permitem até 15 épocas e param após duas épocas sem melhoria de val_loss, recuperando os pesos da melhor época: (i) apenas paragem; (ii) paragem e dropout 0,5; (iii) paragem, dropout e aumento de dados com inversão horizontal e rotação até cerca de 18°. O aumento atua apenas no treino. A regra de seleção, definida antes da comparação, foi minimizar val_loss; o teste permaneceu separado.

3. Resultados e discussão

3.1 Validação e escolha do modelo

Configuração	Épocas	Época guardada	val_loss	val_accuracy
CNN + paragem	5	3	0,7782	70,82%
CNN + dropout	8	6	0,7386	72,18%
CNN + aumento	7	5	0,7748	70,64%

A CNN com dropout teve a menor perda de validação. A sua maior accuracy de validação ocorreu na época 5 (72,64%), mas os pesos guardados pertencem à época 6, pois esta teve a menor perda. Na CNN original, a accuracy de treino chegou a 99,62% na época 10, enquanto a perda de validação subiu para 1,4487; isto sugere sobreajuste. A paragem e o dropout reduziram essa degradação. Nesta execução, o aumento de imagens não melhorou a validação.

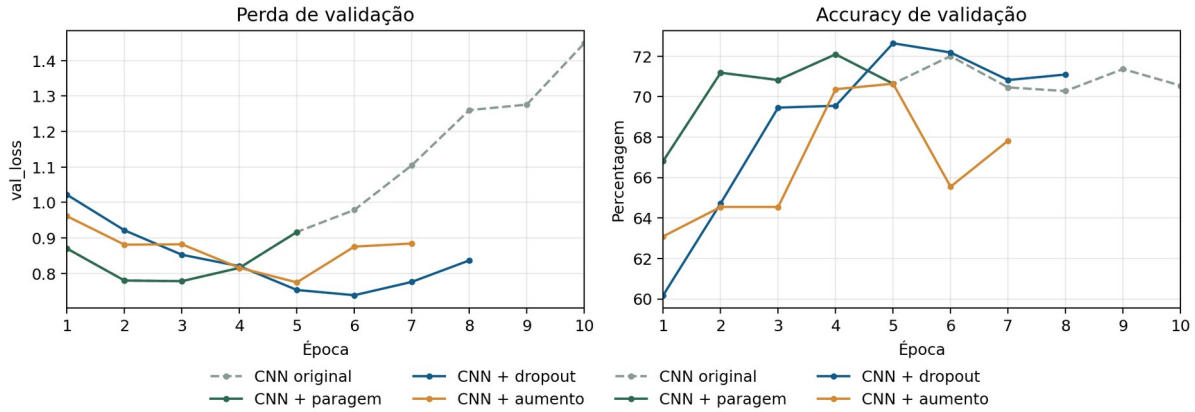


Figura 1 — Históricos de validação das CNN. A linha da CNN original prossegue até à época 10.

3.2 Avaliação no teste independente

Depois de escolher a CNN com dropout pela validação, avaliou-se essa CNN e a MLP original nas mesmas 1 100 imagens de teste, 220 por espécie. As métricas por classe usam a classe em análise contra as outras quatro; os valores macro são médias simples das cinco classes. Por serem equilibradas, a accuracy e o recall macro coincidem. A AUC mede a ordenação das probabilidades, e não a fração de previsões corretas.

Modelo	Accuracy	Recall	Especificidade	F1	AUC
MLP	47,55%	47,55%	86,89%	45,28%	81,89%
CNN + dropout	74,00%	74,00%	93,50%	74,25%	93,49%

A CNN acertou 814 imagens, contra 523 da MLP: mais 291 acertos e 26,45 pontos percentuais de accuracy. Os 74,00% no teste estão próximos dos 72,18% de validação na época escolhida, o que apoia a generalização dentro deste dataset. Esta proximidade não prova o mesmo desempenho em fotografias recolhidas por caminhantes noutros contextos.

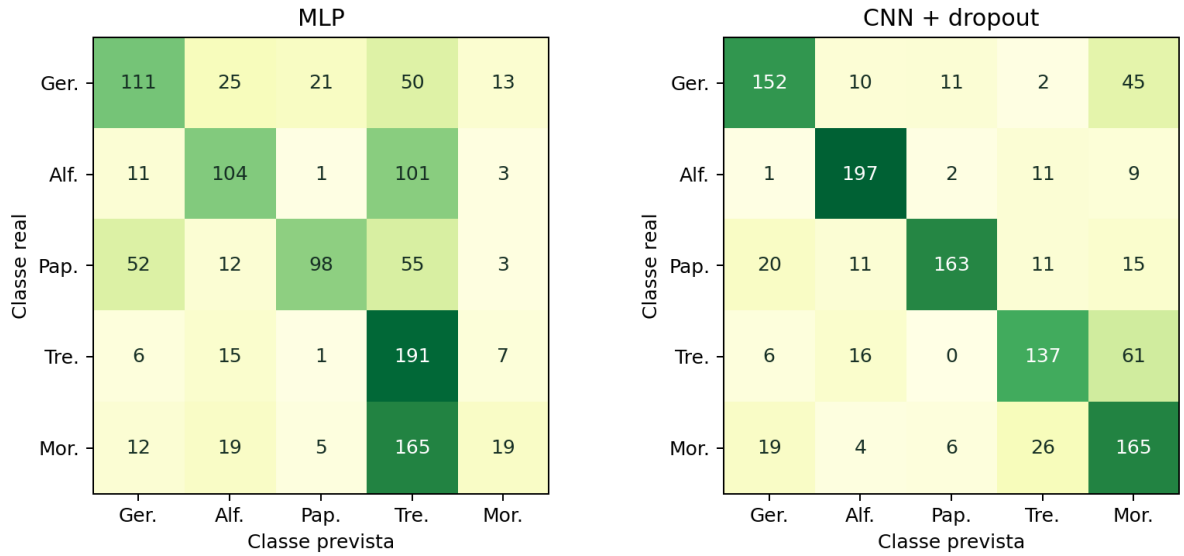


Figura 2 — Matrizes de confusão no teste (contagens). Ger.=gerânio; Alf.=alfazema; Pap.=papoila; Tre.=trevo-branco; Mor.=morangueiro.

3.3 Erros e limitações

A MLP previu trevo-branco para 562 imagens e reconheceu apenas 19 dos 220 morangueiros (recall de 8,64%); classificou 165 morangueiros como trevo-branco. A CNN reduziu essa tendência, mas classificou 61 trevos como morangueiro e 45 gerânios como morangueiro. Na CNN, a alfazema teve o maior recall (89,55%) e o trevo-branco o menor (62,27%). As matrizes mostram quais classes se confundem; sem inspeção visual individual, não é possível atribuir essas falhas a órgãos, fundos, iluminação ou eventuais rótulos incorretos.

O problema é fechado: toda a fotografia recebe uma das cinco classes, mesmo que a espécie real esteja fora delas. Não existe ainda uma regra calibrada para resultado inconclusivo nem uma base de dados de riscos de ingestão ou contacto. As fotografias do Pl@ntNet podem diferir das imagens obtidas em caminhadas, e a verificação da amostra não substitui uma auditoria de todos os rótulos. Portanto, o modelo não deve ser usado para decidir se uma planta é comestível ou segura.

4. Conclusões

Neste subconjunto equilibrado, a CNN com dropout superou claramente a MLP em todas as métricas globais do teste. As convoluções aplicam filtros locais partilhados; a MLP recebe os píxeis achatados e não incorpora essa estrutura na arquitetura. A experiência não isola todas as causas da diferença. A escolha por validação antes do teste evitou usar o teste para ajustar o modelo. O HikeFlora dispõe assim de um classificador inicial para cinco espécies, mas ainda apresenta confusões relevantes e não identifica plantas fora dessas classes.

Nas Metas II e III oficiais, recomenda-se analisar fotografias mal classificadas, comparar modelos mais robustos, estudar calibração e rejeição de espécies desconhecidas e só depois desenvolver as fichas informativas e o protótipo. A informação de risco deve vir de fontes documentadas, não da previsão visual isolada.

Referências

[1] Unidade curricular de Inteligência Computacional, «Projeto — Meta I», enunciado 2026/27, pp. 1–4.

[2] Grupo HikeFlora, «Proposta de tema — HikeFlora», apresentação da Meta 0, 2026/27.

[3] Pl@ntNet-300K-v2, Zenodo, registo 10419064, DOI: 10.5281/zenodo.10419064, https://zenodo.org/records/10419064 (consulta: 10/10/2026).

[4] TensorFlow/Keras, documentação da API tf.keras, https://www.tensorflow.org/api_docs/python/tf/keras (consulta: 10/10/2026).